Selección y Tratamiento de Variables

Evaluación 2 (EV2) - Machine Learning · Predicción de Hits en Spotify (Caso C)

> **Problema de Negocio:** Clasificación supervisada binaria para predecir si una pista será un *hit* comercial (popularidad ≥ P80, umbral ≥ 52 en Train) utilizando características de audio y género musical para orientar presupuestos de marketing discográfico.
> **Dataset Original:** 114.000 filas y 21 columnas crudas → **Dataset Limpio:** 89.740 canciones únicas.
> **Matriz Predictora Final (X):** 128 variables explicativas → **Target (y):** 1 variable binaria (hit = 1 o 0).

1. Variables Descartadas de la Matriz Predictora (X)

Para evitar sobreajuste, sesgos artificiales y fuga de información (*data leakage*), se excluyeron o apartaron las siguientes variables del espacio de entrenamiento de los modelos:

Variable	Decisión	Justificación Técnica y de Negocio
Unnamed: 0	ELIMINADA	Índice correlativo de fila generado automáticamente al guardar el CSV. Ruido técnico sin valor semántico ni predictivo.
track_id	EXCLUIDA DE X	Identificador alfanumérico único. Incluirlo forzaría memorización de identificadores sin generalización. Se conserva en `id_train.csv` e `id_test.csv` únicamente para trazabilidad de predicciones.
artists **album_name** **track_name**	EXCLUIDAS DE X	**Fuga Histórica y Alta Cardinalidad:** Cadenas de texto con decenas de miles de valores. Predecir hits por el nombre del artista introduciría un sesgo de popularidad previa (Bad Bunny o Drake siempre serían hits por su nombre), desvirtuando el objetivo de negocio de evaluar el potencial acústico de una obra. *Uso aplicado:* Se normalizaron para crear la clave de agrupación `song_key` (Artista + Título) y aplicar un `GroupShuffleSplit` que garantiza que versiones de una misma canción no caigan a la vez en Train y Test.
popularity *(continua 0–100)*	TARGET LEAKAGE	**Fuga Directa de la Variable Objetivo:** No es admisible predecir si una canción es hit utilizando su propia popularidad continua como predictor. Se apartó de X y se utilizó de forma exclusiva para calcular el umbral P80 en Train (52) y generar la etiqueta binaria supervisada `hit` (y).

n_generos	**EXCLUIDA DE X**	Conteo de cuántos géneros tiene una canción (calculado durante la deduplicación). Se descartó como feature porque actúa como proxy indirecto de popularidad: las discográficas asignan intencionalmente canciones comerciales a múltiples playlists y subgéneros.
duration_ms **speechiness** **instrumentalness** **liveness** *(escalas crudas)*	**TRANSFORMADAS**	**Asimetría y Outliers Extremos:** En sus escalas crudas presentan sesgo severo (ej. `duration_ms` con asimetría > 10). Se retiraron sus columnas directas y se sustituyeron por sus versiones transformadas con `log1p`.

2. Variables Mantenidas en la Matriz Predictora (X) (128 Features)

Las 128 variables del modelo final se procesaron dentro del `Pipeline` oficial de scikit-learn garantizando aislamiento estricto por pliegue (fold):

Grupo de Variables	Tratamiento	Detalle y Justificación Técnica
Audio Continuas (Directas) • danceability • energy • loudness • valence • tempo	**StandardScaler** (dentro del Pipeline)	Distribuciones simétricas estables. Se escalan a media 0 y varianza 1 dentro del pipeline para homogeneizar magnitudes (evitando que tempo domine a valence) sin filtrar estadísticas entre folds.
Audio Asimétricas (Log) • duration_ms_log • speechiness_log • instrumentalness_log • liveness_log	**log1p** + **StandardScaler**	Se aplica `log(1 + x)` para estabilizar la varianza y reducir el impacto desmedido de outliers de duración o audios hablados. Posteriormente se estandarizan con `StandardScaler`.
Categóricas Musicales • key (tono: 0 al 11) • time_signature (compás)	**OneHotEncoder** (sparse=False)	Aunque vienen registradas como enteros, son variables *nominales*. Un tono musical mayor (ej. Si = 11) no posee una magnitud matemática superior a Do (= 0). El OHE previene relaciones de orden falsas.
Binarias Directas • explicit (0 o 1) • mode (0 menor, 1 mayor)	**Passthrough**	Pasan de forma directa. La variable `explicit` posee un impacto de mercado medible: el hit rate de canciones explícitas es del 29.6% vs 20.2% en no explícitas.
Géneros Musicales • 114 columnas binarias (`genre_acoustic` ⋯ `genre_world-music`)	**MultiLabelBinarizer** (Multi-Hot)	**El Factor Predictivo Principal:** El 18.2% de las pistas pertenecen a múltiples estilos musicales. El multi-hot conserva toda la información de estilo. *Aporte medido:* El análisis de ablación demostró que el género incrementa el AUC en **+0.1615** (el modelo cae de 0.856 a 0.695 sin género).

3. Síntesis Arquitectónica: De Datos Crudos a Matrices de Modelado

Etapa	Archivo / Carpeta	Dimensiones	Descripción del Contenido
1. Datos Crudos	`data/raw/Spotify_Tracks_Dataset.csv`	114.000 filas × 21 cols	Catálogo original completo con duplicados y columnas sin procesar.
2. Split Raw	`data/raw/train/raw_train.csv` `data/raw/test/raw_test.csv`	Train: 71.706 × 124 cols Test: 18.034 × 124 cols	Canciones únicas deduplicadas, popularidad continua intacta y columnas multi-hot de género. Aislado por `song_key`.

3. Processed (Modelos)	`data/processed/train/X_train.csv`
	`data/processed/train/y_train.csv`
	`data/processed/test/X_test.csv`
	`data/processed/test/y_test.csv`
		X: 128 variables explicativas
		y: 1 etiqueta binaria (hit)
		
		Filas: 71.706 tr / 18.034 te
			Matrices listas para los algoritmos. Sin metadatos ni índices. Variables numéricas tratadas con log1p y target binario P80 ≥ 52.

4. Impacto Directo en los KPIs de Negocio

El esquema de selección y tratamiento de variables asegura el cumplimiento estricto de los cuatro KPIs definidos para el proyecto:

1. AUC-ROC ≥ 0.80 → 0.8569 (Cumplido)
La inclusión estructurada de las 114 variables de género aporta +0.1615 de AUC neto, elevando la capacidad de ordenamiento global sobre el umbral de viabilidad comercial.

2. Gap AUC train-test < 0.05 → 0.0255 (Cumplido)
Excluir identificadores de alta cardinalidad (`track_id`, `artists`) y aislar el escalador dentro del `Pipeline` previene sobreajuste por memorización.

3. Recall ≥ 0.75 → 0.8331 (Cumplido)
Conservar temas multigénero mediante `MultiLabelBinarizer` y balancear clases (`class_weight='balanced'`) asegura detectar más del 83% de los éxitos reales.

4. Lift @ 10% ≥ 2.0 → 3.36 (Cumplido)
Enfocar el presupuesto en el 10% de canciones con mayor probabilidad captura 3.36 veces más éxitos que una selección aleatoria, maximizando el ROI en marketing.