Selección y Tratamiento de Variables

Evaluación 2 (EV2) - Machine Learning · Predicción de Hits en Spotify (Caso C)

Problema de Negocio: Clasificación supervisada binaria para predecir si una pista será un hit comercial (popularidad ≥ P80, umbral ≥ 52 en Train) utilizando características de audio, género musical y variables simples del texto para orientar presupuestos de marketing discográfico.
Dataset Original: 114.000 filas y 21 columnas crudas → **Dataset Limpio:** 89.740 canciones únicas.
Matriz Predictora Final (X): 133 variables explicativas → **Target (y):** 1 variable binaria (hit = 1 o 0).

1. Variables Descartadas de la Matriz Predictora (X)

Para evitar sobreajuste, sesgos artificiales y fuga de información (data leakage), se excluyeron o apartaron las siguientes variables del espacio de entrenamiento de los modelos:

Variable	Decisión	Justificación Técnica y de Negocio
Unnamed: 0	ELIMINADA	Índice correlativo de fila generado automáticamente al guardar el CSV. Ruido técnico sin valor semántico ni predictivo.
track_id	EXCLUIDA DE X	Identificador alfanumérico único. Incluirlo forzaría memorización de identificadores sin generalización. Se conserva en id_train.csv e id_test.csv únicamente para trazabilidad de predicciones.
artists album_name track_name	EXCLUIDAS DE X (como texto)	**Fuga Histórica y Alta Cardinalidad:** cadenas de texto con decenas de miles de valores. Predecir hits por el nombre del artista introduciría un sesgo de popularidad previa, desvirtuando el objetivo de negocio de evaluar el potencial de una obra. **Uso aplicado:** se normalizaron para crear la clave de agrupación song_key (Artista + Título) y aplicar un GroupShuffleSplit que garantiza que versiones de una misma canción no caigan a la vez en Train y Test. De artists y track_name se derivan además 5 variables simples que **no identifican al artista** (sección 2).
popularity (continua 0–100)	TARGET LEAKAGE	**Fuga Directa de la Variable Objetivo:** no es admisible predecir si una canción es hit utilizando su propia popularidad continua como predictor. Se apartó de X y se utilizó de forma exclusiva para calcular el umbral P80 en Train (52) y generar la etiqueta binaria hit (y).
n_generos	EXCLUIDA DE X	Conteo de cuántos géneros tiene una canción (calculado durante la deduplicación). Se descartó como feature porque actúa como proxy indirecto de popularidad. Como el multi-hot lo lleva implícito, la política de umbral corrige el sobre-marcado de canciones con 3 o más géneros (sección 4).
duration_ms speechiness instrumentalness liveness (escalas crudas)	TRANSFORMADAS	**Asimetría y Outliers Extremos:** en sus escalas crudas presentan sesgo severo (ej. duration_ms con asimetría > 10). Se retiraron sus columnas directas y se sustituyeron por sus versiones transformadas con log1p.

2. Variables Mantenidas en la Matriz Predictora (X) (133 Features)

Las 133 variables del modelo final se procesaron dentro del Pipeline oficial de scikit-learn garantizando aislamiento estricto por pliegue (fold):

Grupo de Variables	Tratamiento	Detalle y Justificación Técnica
Audio Continuas (Directas) • danceability • energy • loudness • valence • tempo • acousticness	StandardScaler (dentro del Pipeline)	Se escalan a media 0 y varianza 1 dentro del pipeline para homogeneizar magnitudes (evitando que tempo domine a valence) sin filtrar estadísticas entre folds.
Audio Asimétricas (Log) • duration_ms_log • speechiness_log • instrumentalness_log • liveness_log	log1p + StandardScaler	Se aplica log(1 + x) para estabilizar la varianza y reducir el impacto desmedido de outliers de duración o audios hablados. Posteriormente se estandarizan.

Grupo de Variables	Tratamiento	Detalle y Justificación Técnica
Categóricas Musicales • key (tono: 0 al 11) • time_signature (compás)	OneHotEncoder	Aunque vienen registradas como enteros, son variables nominales: un tono Si (= 11) no posee una magnitud superior a Do (= 0). El OHE previene relaciones de orden falsas.
Binarias Directas • explicit (0 o 1) • mode (0 menor, 1 mayor)	Passthrough	Pasan de forma directa. La variable explicit posee un impacto de mercado medible: el hit rate de canciones explícitas es del 29.6% vs 20.2% en no explícitas.
Texto sin identidad del artista • n_artistas • t_palabras • t_remix • t_live • t_feat	StandardScaler (n_artistas, t_palabras) Passthrough (marcas 0/1)	Número de artistas (colaboraciones) y marcas en el título (remix, live, feat., cantidad de palabras). No usan el target ni el nombre del artista. **Aporte medido:** +0.003 de AUC en CV (sección 13 del notebook 2).
Géneros Musicales • 114 columnas binarias (genre_acoustic ... genre_world-music)	MultiLabelBinarizer (Multi-Hot)	**El Factor Predictivo Principal:** el 18.2% de las pistas pertenecen a múltiples estilos musicales; el multi-hot conserva toda la información de estilo. **Aporte medido:** la ablación muestra que el género incrementa el AUC de CV en +0.161 (0.868 con género, 0.707 sin género).

3. Síntesis Arquitectónica: De Datos Crudos a Matrices de Modelado

Etapa	Archivo / Carpeta	Dimensiones	Contenido
1. Datos Crudos	data/raw/Spotify_Tracks_Dataset.csv	114.000 filas × 21 cols	Catálogo original completo con duplicados y columnas sin procesar.
2. Split Raw	data/raw/train/raw_train.csv data/raw/test/raw_test.csv	Train: 71.706 × 124 cols Test: 18.034 × 124 cols	Canciones únicas deduplicadas, popularidad continua intacta y columnas multi-hot de género. Aislado por song_key.
3. Processed (Modelos)	data/processed/train/X_train.csv data/processed/train/y_train.csv data/processed/test/X_test.csv data/processed/test/y_test.csv	X: 133 variables y: 1 etiqueta binaria (hit) Filas: 71.706 tr / 18.034 te	Matrices listas para los algoritmos, sin metadatos ni índices. Numéricas con log1p, variables de texto y target binario P80 ≥ 52.

4. Impacto Directo en los KPIs de Negocio

El esquema de selección y tratamiento de variables, junto con la política de umbral del modelo oficial (HistGradientBoosting), asegura el cumplimiento de los cuatro KPIs:

1. AUC-ROC ≥ 0.80 → 0.8663 (Cumplido)
La inclusión estructurada de las 114 variables de género aporta +0.161 de AUC de CV, y las variables de texto +0.003, elevando la capacidad de ordenamiento global.

2. Gap AUC train-test < 0.05 → 0.0299 (Cumplido)
Excluir identificadores de alta cardinalidad (track_id, artists), aislar el escalador dentro del Pipeline y exigir min_samples_leaf = 20 con regularización L2 previene el sobreajuste por memorización.

3. Recall ≥ 0.75 → 0.7909 (Cumplido)
La política de umbral por género y número de géneros se calibra para recall 0.78 fuera de muestra en train. Detecta el 79% de los éxitos reales y reparte mejor el recall: en géneros de nicho sube de 0.14 (umbral 0.5) a 0.35.

4. Lift @ 10% ≥ 2.0 → 3.43 (Cumplido)
Enfocar el presupuesto en el 10% de canciones con mayor probabilidad captura 3.43 veces más éxitos que una selección aleatoria.